皮肤病灶分割模型比较
与自动提示级联实验

姓名：王春博　　学号：202620000613

机器学习课程作业一与作业二

2026 年 10 月 29 日

一 摘要

本报告围绕 ISIC 2018 皮肤病灶分割，完成课程作业一的卷积网络实现与作业二的 Transformer 复杂模型实验。采用 2594 张训练图像、100 张验证图像和 1000 张测试图像，比较 U-Net、ResUNet、Attention U-Net 及 SAM 三种适配阶段，并以 U-Net 自动提框连接两项作业。卷积网络三种子 Dice 均值约为 0.594—0.608，结构差异带来的收益有限；修复后 E2 在 GT 框下 Dice 为 0.9181，E3 自动框级联为 0.7559，提示来源明显影响性能。实验进一步分析损失函数、输入尺度、门控位置和提示扰动，并展示相同测试样本的真实标签与预测。代码审查后修复缓存监督、完整权重恢复和续跑保存逻辑；问题实验已重新训练并完成全量复评，原结果单独归档。主要收获是结合失败样本、计算预算和提示条件解释指标，而非只依据最高分选择模型。

关键词：医学图像分割；U-Net；Transformer；SAM；LoRA；自动提示

目 录

一 摘要.....1

二 引言.....3

三 实验模型原理介绍.....3

四 实验设计.....10

五 实验结果分析.....12

六 报告总结.....16

参考文献.....17

附录 A 完整实验数据.....18

附录 B 修复验证与快速复现.....23

附录 C 实际前端与电子图录.....24

二 引言

皮肤镜图像中毛发、低对比度边缘和病灶尺度差异，使前景覆盖与边界贴合难以同时改善。课程作业一允许基于皮肤癌数据实现医学图像分割；本项目选择手写 U-Net 及其残差和注意力变体，以相同数据和评价口径比较结构。作业二要求至少使用一处 Transformer，并建议学习 SAM 和提示工程，因此在同一任务上引入 SAM ViT-B，研究预训练模型的零样本、局部微调与低秩适配。

U-Net 以跳跃连接融合定位信息与深层语义[1]，残差网络和空间门控分别改变块内信息流与跨层特征选择[2][3]。SAM 通过图像编码、提示编码和掩膜解码实现可提示分割[4]。本报告以 ISIC 2018 Task 1 为共同数据基础[5]，关注三个问题：复杂结构能否稳定提升结果；超参数与提示条件怎样影响表现；自动提示能否把两个作业组成可运行系统。

报告按课程要求组织为摘要、引言、模型原理、实验设计、结果分析和总结。总体比较、超参数比较与测试案例分别见第五部分；个人观点在第六部分高亮。全部逐次运行数据集中于附录，源码与快速复现命令随包交付。

三 实验模型原理介绍

3.1 U-Net 编码与解码

结构图展示本项目 U-Net 的实际数据流。其编码—解码与跳跃连接思想源于文献[1]。卷积通过局部感受野提取纹理与边缘，批归一化调整中间激活，ReLU 提供非线性。DoubleConv 由两次无偏置 3×3 卷积、BN 和 ReLU 组成，padding=1 保持空间尺寸。下采样块先进行 2×2 最大池化，再增加通道。深层特征覆盖更大的输入范围，代价是空间细节减少；解码侧逐级上采样，与同尺度编码特征在通道维 concat，再进行卷积融合。

默认 bilinear=True，实际使用双线性插值与 1×1 卷积，而非默认转置卷积。Up 在尺寸不齐时进行中心 padding；输出层仅有 1×1 卷积，把 64 通道变成单通道 logits。sigmoid 在损失或评测时执行，网络末端没有 softmax。

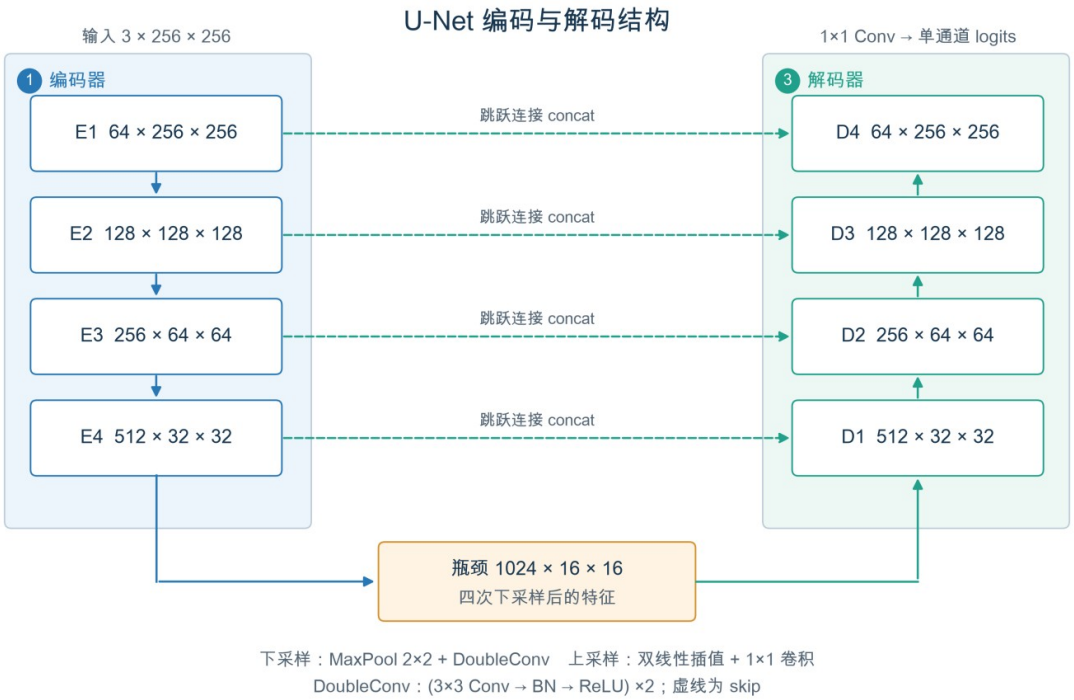


图 1　U-Net 编码与解码结构

注：依据实际模型源码绘制；蓝色为编码路径，绿色为解码路径，橙色为瓶颈或门控。

3.2 ResUNet 残差学习

结构图展示残差块与跨层拼接在本实现中的不同位置。参考残差 U-Net 的组合思路[2]，残差块输出为 ReLU(F(x)+S(x))。F 包含两次卷积和 BN；当通道数或空间步长变化时，S 使用 1×1 卷积与 BN 对齐，否则为恒等映射。加法发生在块内部；编码器和解码器间仍然 concat，不能将这两类连接混为一谈。

ResUNet 的下采样采用 stride=2 的残差卷积，解码仍采用双线性插值、1×1 卷积与残差块。因此本实验同时改变了块结构和下采样方式，不能把结果全部归因于某一条残差通路。残差形式使梯度存在较直接的传播路径，但是否改善本任务收敛，仍需依据训练过程判断。

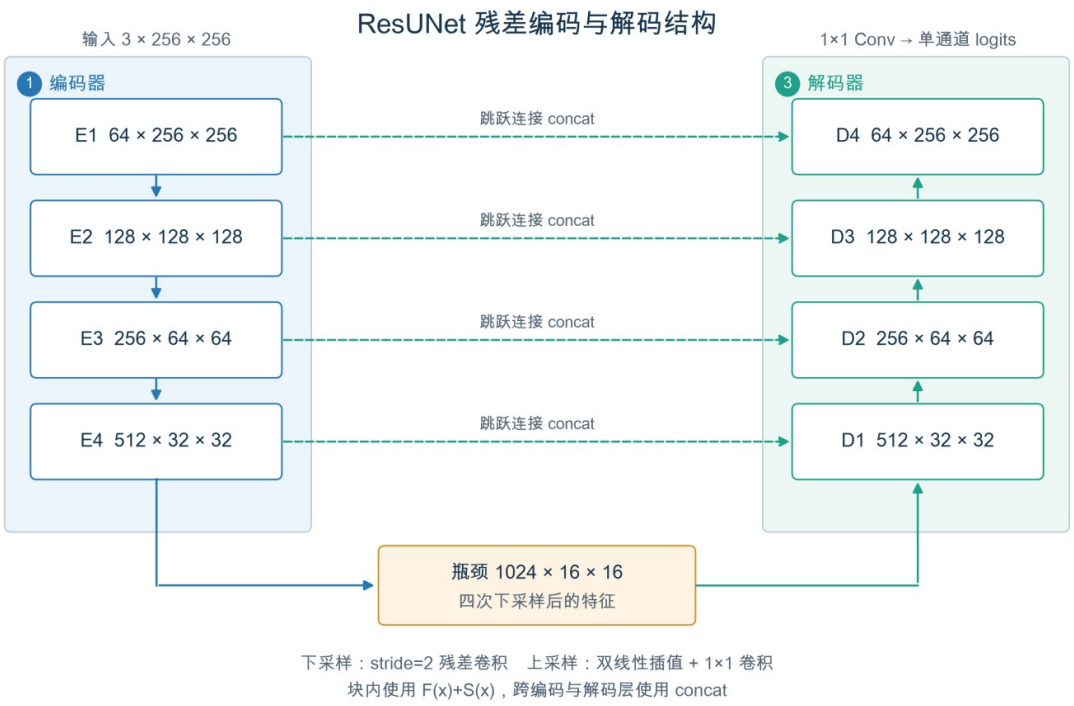


图 2 ResUNet 残差编码与解码结构

3.3 Attention U-Net 空间门控

结构图展示四个跳跃层上的门控位置。参考 Attention U-Net 的空间筛选机制[3]，注意力门接收编码特征 x 与更深层解码特征 g；先将 g 双线性插值到 x 的尺度，用两个 1×1 卷积统一通道后相加。简化表达为：

$$\alpha = \sigma\left(BN\left(\psi\left(ReLU\left(W_x x + W_g g\right)\right)\right)\right), \hat{x} = \alpha \odot x \qquad (1)$$

α 是单通道空间权重图，广播乘到所有 skip 通道，不是每个通道独立评分，也不是 Transformer 自注意力。默认 all 使用 g1、g2、g3、g4；skip 仅启用浅层 g1/g2；bottleneck 仅启用靠近瓶颈的 g4 跳跃连接，并没有在瓶颈主干加入 Transformer。门控可抑制部分无关位置，但也可能压低有用边界信息，需通过实际结果检验。

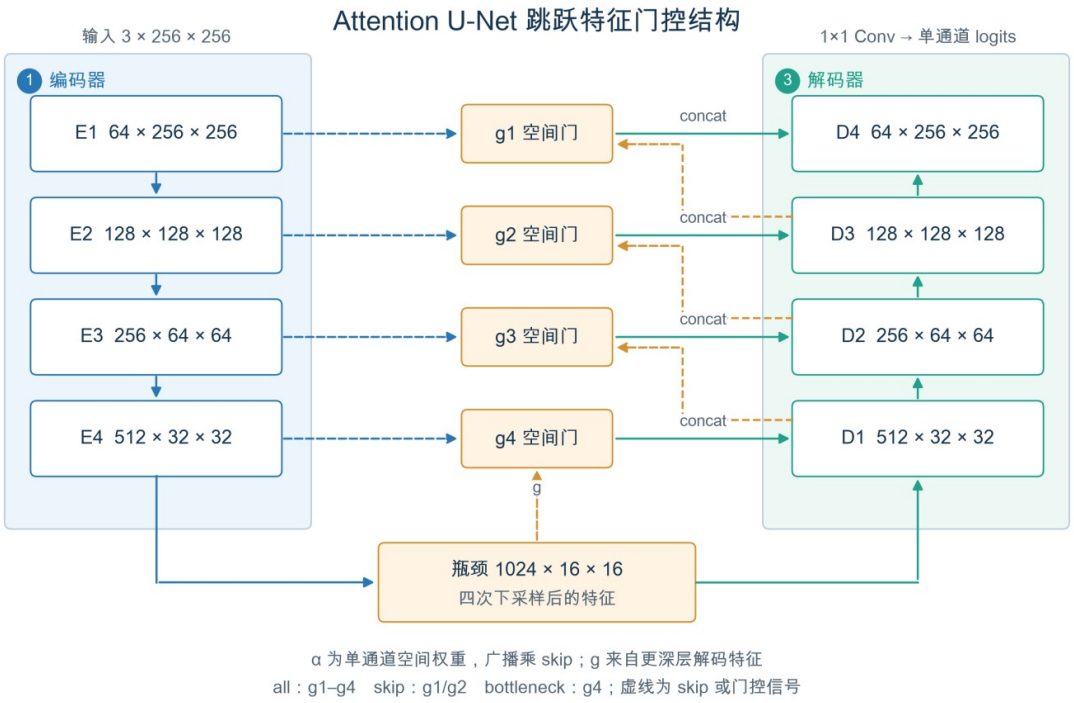


图 3　Attention U-Net 空间门控结构

3.4 SAM 与视觉 Transformer

SAM 采用 ViT-B 图像编码器、提示编码器和 Two-Way 掩膜解码器[4]。本实现从 384 母版读取 256 网格，再缩放为 1024 输入；坐标同步乘 4，输出与评价回到 256 网格。放大输入不会恢复母版丢失的细节，直接正方形缩放也与官方保持长宽比的预测流程不同。

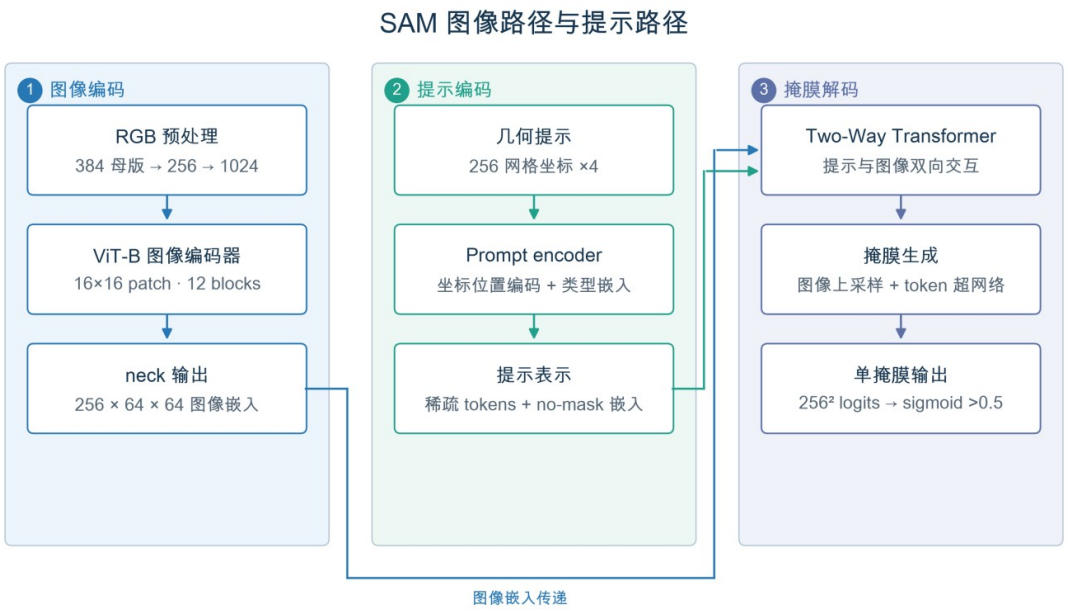


图 4　SAM 图像与提示双路径

Transformer 通过查询 Q、键 K 和值 V 进行内容相关的信息聚合[6]：

$$Attention(Q,K,V)=softmax(QK^{\top}/\sqrt{d_k})V \qquad (2)$$

ViT 将图像划分为 patch 序列[7]。本项目 ViT-B 采用 16×16 patch、12 层、768 维、12 头，得到 64×64 网格；零起始层 2、5、8、11 使用全局注意力，其余使用窗口注意力，neck 输出 256×64×64 嵌入。此处与深度 2、8 头的 Two-Way 解码器均实际使用 Transformer，满足作业二要求。空间门控仅产生单通道权重，与 Q/K/V 注意力机制不同。

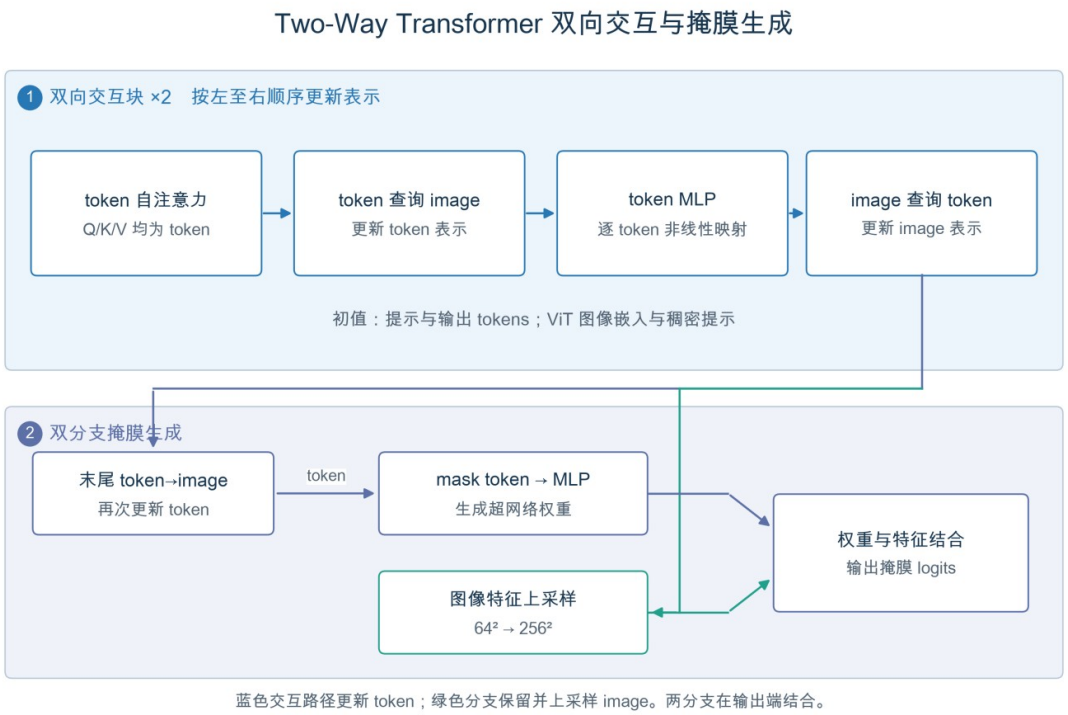


图 5　Two-Way Transformer 双向交互与掩膜生成

提示编码器以位置和类型嵌入表示框角点或前景点；未使用 mask 提示时加入 no-mask 嵌入。解码后的 mask token 经 MLP 生成超网络权重，与上采样图像特征结合输出 logits[8]。本项目输出单掩膜，以 sigmoid>0.5 二值化。模型内部 IoU 预测头属于质量估计，测试 IoU 由真实标签计算。

3.5 LoRA 与自动提示级联

LoRA 冻结原投影，以低秩增量调整模型[9]：

$$W_{eff}\,x = W_0\,x + (\alpha / r)\,BAx \qquad (3)$$

本实现 r=8、α=16，12 层 qkv 投影各自建立独立的 A、B 矩阵，并用输出 mask 仅保留 q/v 增量。LoRA 新增 294912 参数；E3 同时训练 prompt 与 decoder，联合优化 4359472 参数。参数节省需按联合优化范围解释。E3 从原版 SAM 独立初始化，未接续 E2。

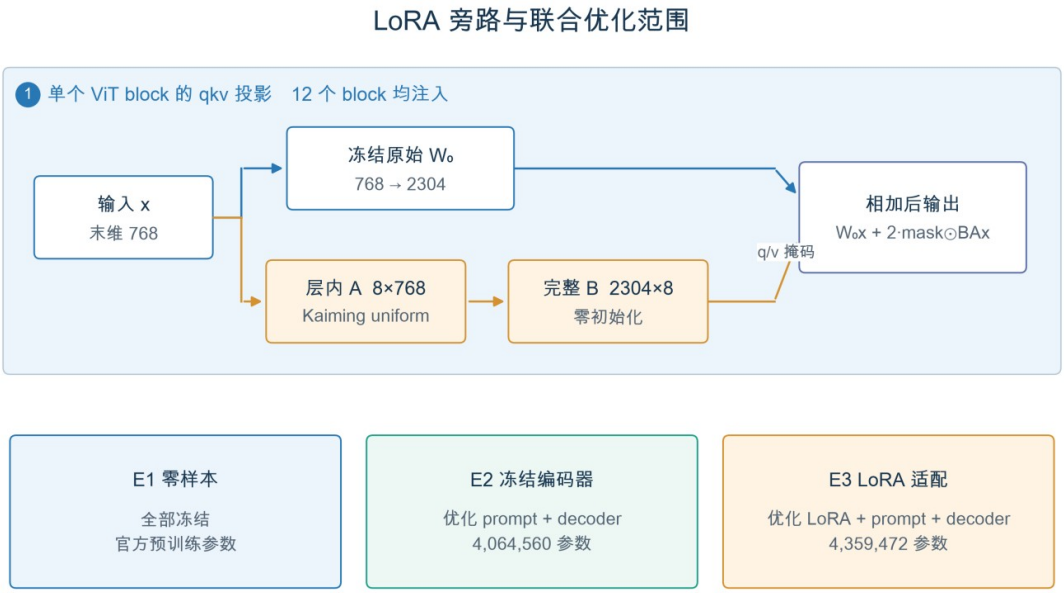


图 6　低秩旁路与三阶段优化范围

自动级联先用 unet_s42 预测掩膜并取外接框，再将框输入 SAM。1000 条自动框中 6 条为空，按全图框回退；auto10 将四边各外扩原框宽高的 10%并截断。GT 只用于级联评价，不能用于生成自动提示。

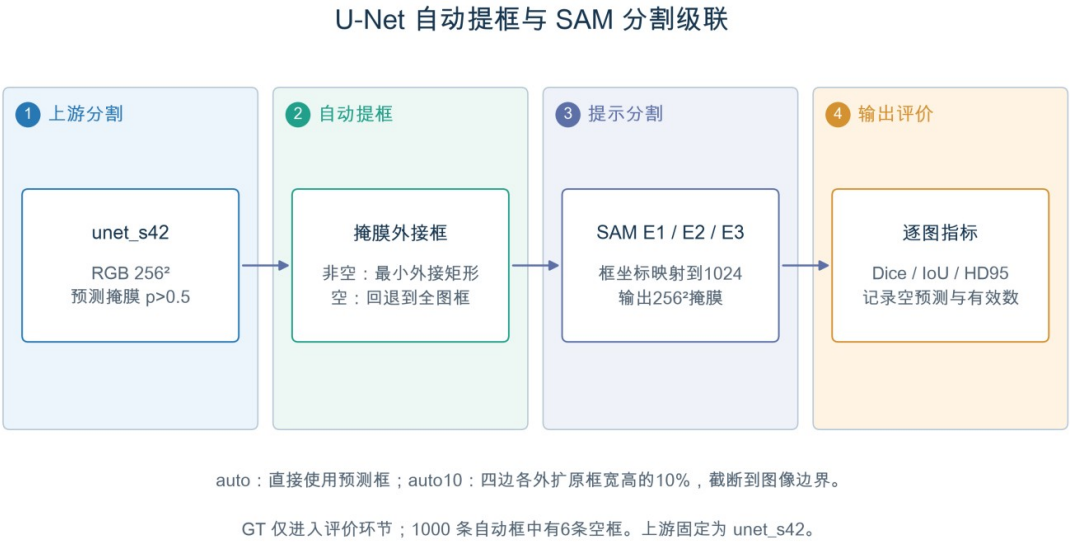


图 7　U-Net 自动提框与 SAM 分割级联

四 实验设计

4.1 数据与预处理

采用 ISIC 2018 Task 1 本地固定划分：train 2594、val 100、test 1000。384 母版病灶前景均值分别为 21.40%、26.84%、27.98%，提示训练与测试尺度分布存在差异。图像按 ID 与掩膜配对；未额外筛选手工特征，网络直接学习 RGB 表示。

卷积网络默认 256 输入，图像使用面积插值、掩膜使用最近邻并二值化；图像除以 255 后按 ImageNet 均值与标准差归一化，网络仍为随机初始化。训练包含翻转、±30°旋转、0.8—1.2 缩放、平移、亮度对比度和噪声；验证测试只缩放与归一化。SAM 沿用同一数据和 256 评价网格。修复后的 E2 保留固定原图嵌入，仅扰动框，取消可能破坏空间监督对应的嵌入翻转。

4.2 指标与损失

逐图计算并对图像平均。TP、FP、FN、TN 分别表示命中前景、误检、漏检和正确背景像素；区域指标为：

$$Dice=\frac{2TP}{2TP+FP+FN},IoU=\frac{TP}{TP+FP+FN} \quad (4)$$

$$Sensitivity=\frac{TP}{TP+FN},Specificity=\frac{TN}{TN+FP} \quad (5)$$

HD95 取两方向最近边界距离各自 95%分位的较大值，单位为评价网格像素。空预测仍进入 Dice/IoU 平均，但不进入 HD95 平均，因此需同时查看空预测与有效计数。灵敏度和特异度描述像素分割，不等同于临床诊断指标。

默认使用 BCE 与 Soft Dice 各占一半的混合损失，其中 p 为 sigmoid 概率，$\varepsilon=10^{-6}$ ：

$$L=0.5L_{BCE}+0.5\left(1-\frac{2\sum_i p_i y_i+\epsilon}{\sum_i p_i+\sum_i y_i+\epsilon}\right) \quad (6)$$

4.3 实验配置与比较变量

表 1　主要实验配置

项目	卷积网络	SAM
模型与阶段	U-Net / ResUNet / Attention U-Net	E1 零样本 / E2 局部微调 / E3 LoRA
训练样本	2594	E2 2594；E3 前 600
优化器与学习率	AdamW；1e-3；余弦调度	AdamW；E2/E3 1e-4
默认输入与 batch	256；8	1024 编码、256 评价；8 / 1×累积 8
设定预算	12 轮上限；patience 6	E2 20 轮；E3 6 轮
重复与变量	三种子；损失、尺寸、门控	框扰动、点数、自动提示

卷积主实验种子为 42、2026、7，均值误差条使用分母 n−1 的样本标准差。消融固定种子 42，比较 BCE/Dice/混合、192/256/384 输入和浅层/深层/全部门控；五折作为补充验证，留出折参与权重选择，其独立性有限。SAM 十类提示包括 GT 框、±10%/±20%扰动框、1/3/5 点、auto 和 auto10；前八类由 GT 构造，属于模拟交互。没有开展 LoRA 秩或学习率搜索。

4.4 实现修复与完整复验

E2 取消缓存特征翻转，保持嵌入、框与 GT 同坐标；E3 完整恢复 LoRA、提示编码器、解码器及缩放参数；训练器在保存 last 前更新 best 和耐心计数，编排按目标轮数验收。数据与权重身份、命令和日志单独存证。

完整复验包括 E2 20 轮、E3 6 轮，以及 384 输入重新训练与测试；E2/E3 各 10 类提示均覆盖 1000 张测试图。三者 best 分别为第 9、2、2 轮，与日志峰值和 last 一致。其余 24 组卷积实验及 E1 核对后保留。E3 同图多提示复用当前模型在线嵌入，重新编码的预测逐像素一致，未使用原版缓存。详细核验见附录 B。

五 实验结果分析

5.1 卷积模型总体比较

九份正式 test JSON 重算得到 U-Net、ResUNet、Attention U-Net 的 Dice 均值分别为 0.5939、0.6077、0.6080。图 8 用误差条呈现重复波动；三次重复不足以支持稳定的结构优势。区域与边界排名不一致，且 HD95 剔除空预测，选择模型时需同时查看失败数量。

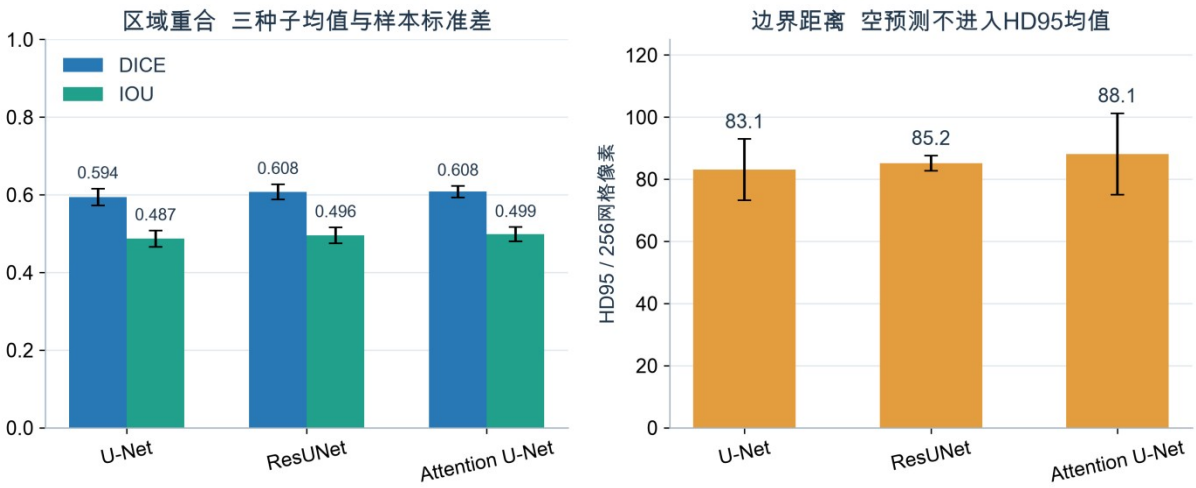


图 8　卷积模型区域与边界指标比较

图 9 保留全部九次验证轨迹，显示同一结构也会出现早期峰值和后续回落。图 10 进一步提供学习率与单轮成本，帮助区分结构差异、优化过程和资源投入；完整逐次分数移至附录 A，正文不再重复铺表。

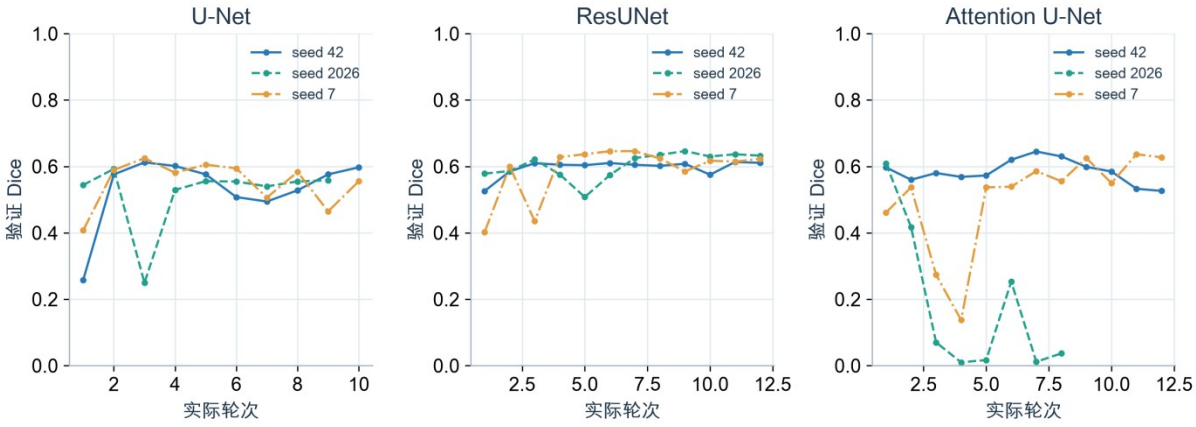


图 9　九次主实验的验证 Dice 轨迹

注：原始轮次直线连接，不进行平滑；颜色和线型共同区分种子。

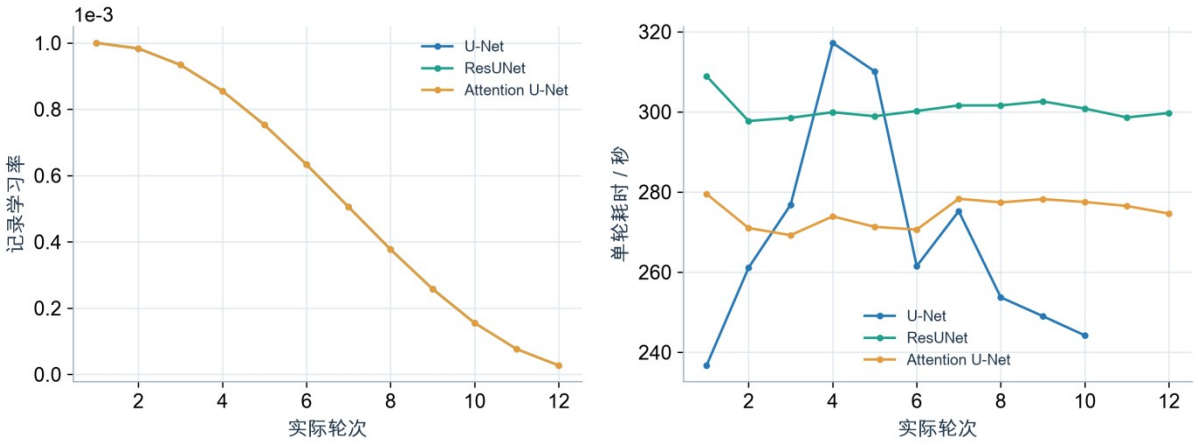


图 10　学习率与每轮训练成本

5.2 超参数与补充验证

图 11 表明本次混合损失比 BCE 具有更好的前景重合，全部门控优于两个局部开关。384 输入修复后 Dice 由 0.4756 变为 0.5810，仍低于 192 输入的 0.6391；两者训练成本、优化轨迹与 HD95 网格不同，不能据此断言低分辨率普遍更优。单种子消融用于提出后续假设，仍需匹配预算并重复验证。

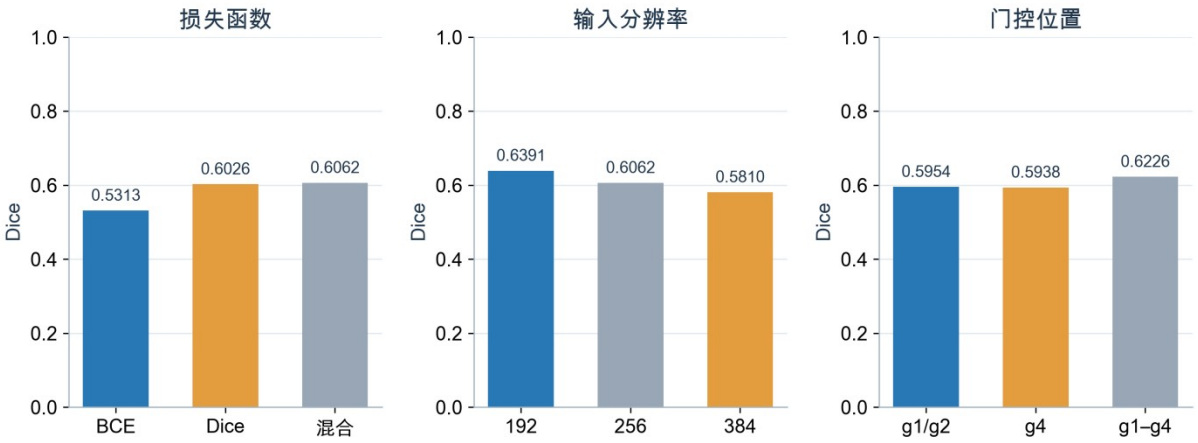


图 11　损失函数输入尺度与门控位置的比较

五折补充验证中 ResUNet 为 0.5698±0.0349，Attention U-Net 为 0.5631±0.0679，后者折间波动更大。留出折同时参与选权重，且模型选择参考过 test 结果，因此不能作为独立嵌套交叉验证证据。各折数据见附录 A。

5.3 SAM 提示工程与自动级联

图 12 将三阶段和十类提示置于同一矩阵。E2 的 GT 框 Dice 为 0.9181，高于 E1 的 0.8691 及 E3 的 0.8970；提示内缩会遗漏边缘，改用点提示也改变了可用的定位信息。本轮 E2 的点数增加改善重合，是否普遍成立仍需多种子验证。E3 只用 600 张训练图像，而 E2 使用 2594 张，因此阶段差异不能单独归因于 LoRA 机制。

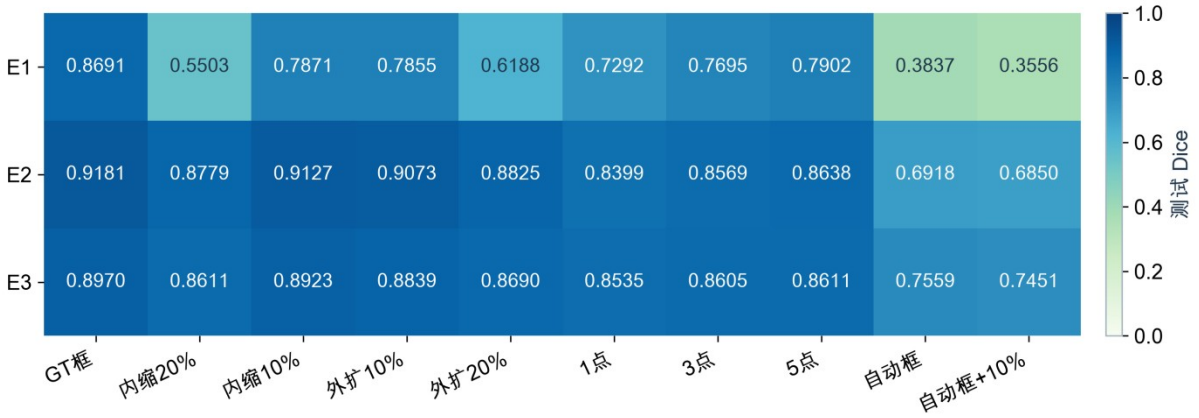


图 12　三阶段十种提示的最终 Dice 矩阵

图 13 显示 GT 框到自动框的性能落差。固定上游 unet_s42 的 Dice 为 0.6062，E2 与 E3 自动框级联分别为 0.6918 和 0.7559；E3 相对上游提高约 14.97 个百分点，自动化能力应在这一路径下讨论。外扩 10%后 E2 为 0.6850、E3 为 0.7451，不能预设外扩必然改善结果。GT 框及前景点由真实标签生成，只代表模拟交互条件。E1/E2 读取原版缓存，E3 在线编码，记录时延不作为统一部署速度比较。

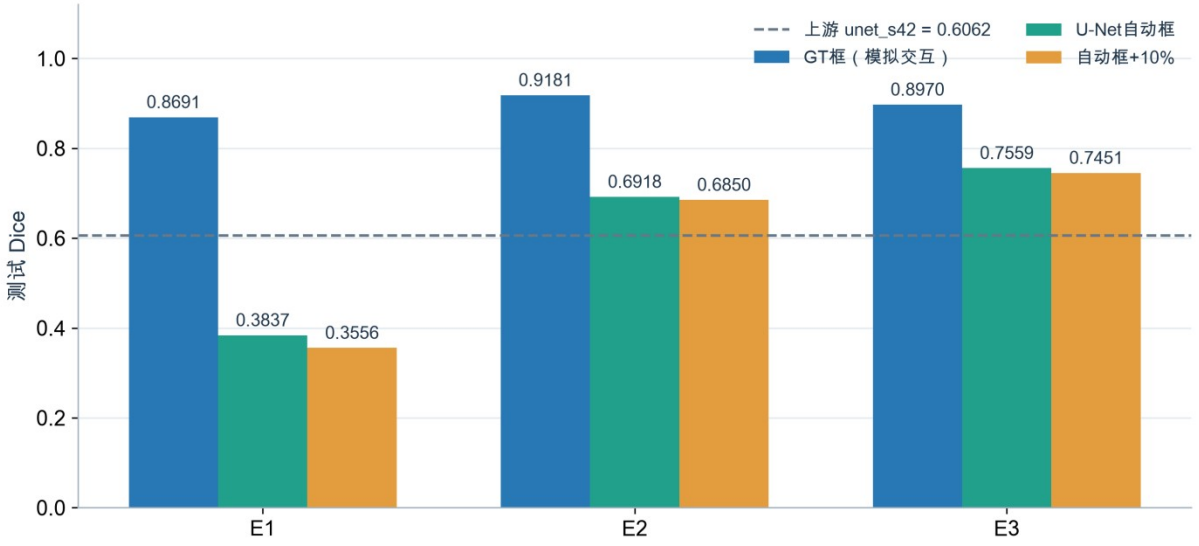


图 13　GT 框与自动框条件的最终比较

5.4 相同测试样本的真实预测

按测试 GT 面积接近 10%、50%、90%分位固定三个样本 ID，两类模型使用相同图像；U-Net 无提示，SAM 使用 GT 框。图 14 保留原图、真实掩膜、预测和误差，直接满足课程对测试案例的要求。小病灶例出现背景误检，大病灶例存在漏检和碎片；分位选样不代表最好或最差结果，三例也不能替代全测试均值。

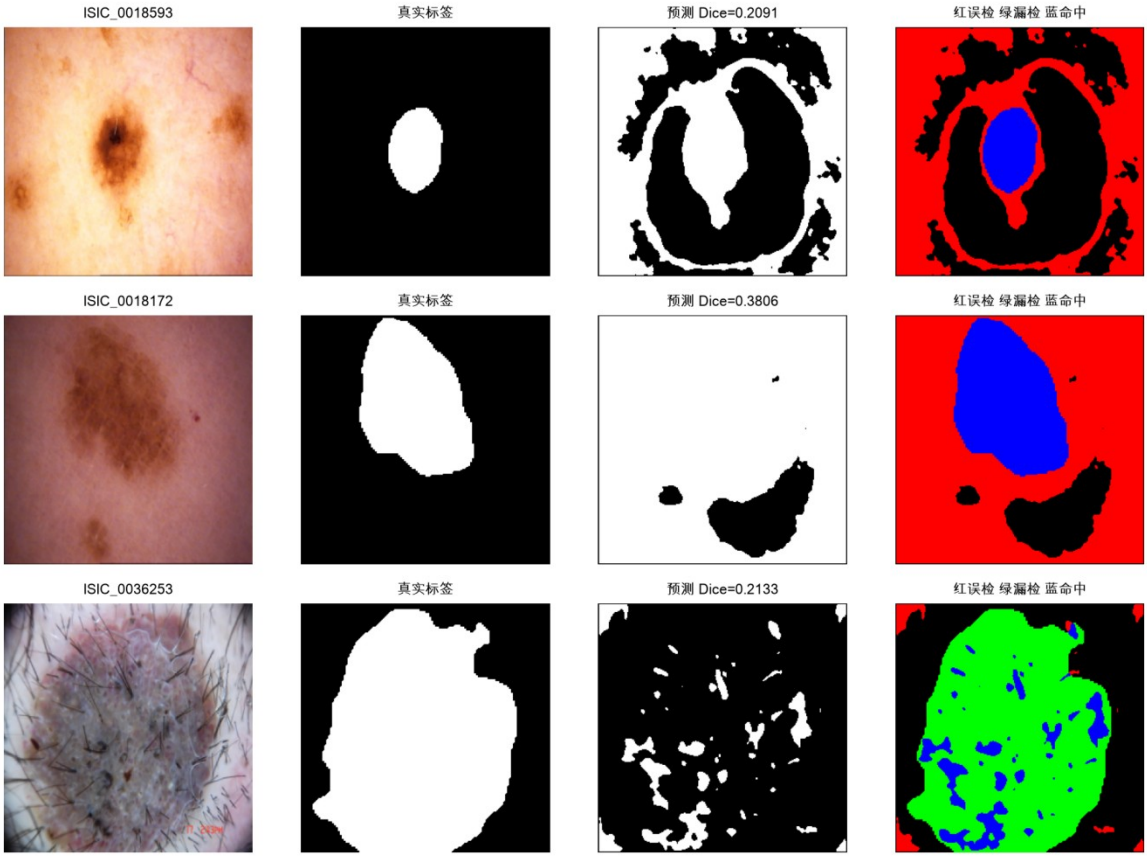


图 14　固定测试样本的 U-Net 预测与误差

图 15 使用新选定权重重新生成同一组三个样本的 GT 框预测，直观对照不同适配方式的边缘覆盖。图中每个 Dice 直接由展示的二值掩膜计算，并与正式全测试 JSON 中相同 ID 的记录核对。该案例补充总体均值，不能代表全体样本的误差分布。

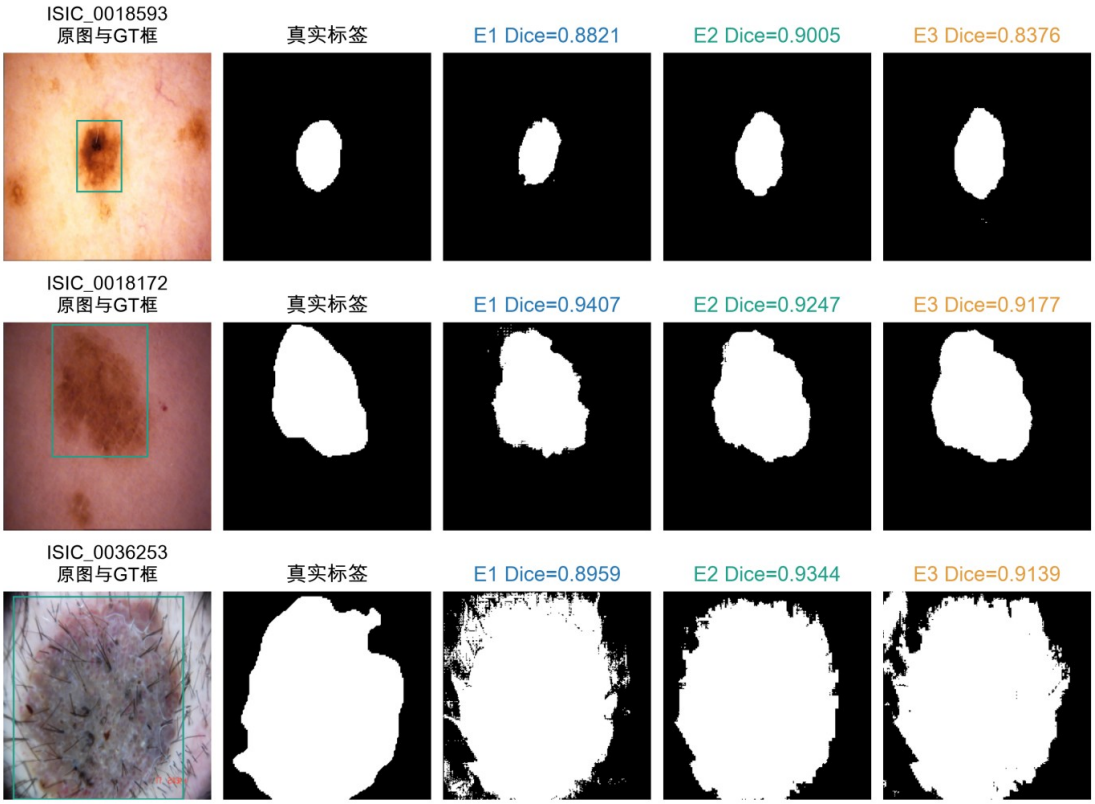


图 15　同样本与 GT 框下的 SAM 最终预测

六 报告总结

本项目完成手写医学分割网络、Transformer 提示分割及自动提框级联，覆盖课程要求的总体比较、超参数比较和实际测试案例。卷积模型的结构收益较小，提示条件对 SAM 影响明显；实验解释必须同时考虑随机波动、数据预算和实现一致性。

个人观点一：先确定模型能获得什么信息，再比较分数。GT 提示使用了测试标注，自动提示才对应无人交互链路；预训练先验和上游成本也应纳入评价。

个人观点二：复杂结构需要稳定证据支撑。残差、门控和 LoRA 都有合理动机，但当前结果不足以说明其普遍优势。预算匹配、多种子重复与失败样本比一次最高分更有说服力。

个人观点三：实现正确性是结论的前提。监督坐标、模块权重恢复及续跑状态必须一致。本次以独立重训和完整评测解决权重缺失，并核对选中轮次与日志峰值；结论随新证据更新。

参考文献

[1] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Cham: Springer, 2015: 234-241. DOI: 10.1007/978-3-319-24574-4_28.

[2] ZHANG Z, LIU Q, WANG Y. Road Extraction by Deep Residual U-Net[EB/OL]. (2017-11-29)[2026-10-28]. https://arxiv.org/abs/1711.10684.

[3] OKTAY O, SCHLEMPER J, LE FOLGOC L, et al. Attention U-Net: Learning Where to Look for the Pancreas[EB/OL]. (2018-05-20)[2026-10-28]. https://arxiv.org/abs/1804.03999.

[4] KIRILLOV A, MINTUN E, RAVI N, et al. Segment Anything[EB/OL]. (2023-04-05)[2026-10-28]. https://arxiv.org/abs/2304.02643.

[5] INTERNATIONAL SKIN IMAGING COLLABORATION. ISIC Challenge Datasets: 2018 Task 1[DB/OL].[2026-10-28]. https://challenge.isic-archive.com/data/#2018.

[6] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems. Vol. 30. 2017. https://papers.nips.cc/paper/7181-attention-is-all-you-need.

[7] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[EB/OL]. (2021-06-03)[2026-10-28]. https://arxiv.org/abs/2010.11929.

[8] META AI RESEARCH. Segment Anything: official implementation[CP/OL].[2026-10-28]. https://github.com/facebookresearch/segment-anything.

[9] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models[EB/OL]. (2021-10-16)[2026-10-28]. https://arxiv.org/abs/2106.09685.

附录 A 完整实验数据

本附录保留支撑正文比较的完整数值。默认网格 256；192/384 消融在各自网格计分。除特别注明外，test n=1000；种子间、折间与逐图离散度不可互换。正式 JSON/CSV 位于 repository 各实验 outputs/logs；E2/E3 及 384 输入已替换为本次复验，其他结果保留。

表 2　数据集划分与病灶前景分布

划分	样本数	前景均值	中位数	5% / 95% 分位	空 / 多连通域
train	2594	21.40%	13.82%	1.55% / 65.18%	0 / 731
val	100	26.84%	21.63%	4.81% / 71.26%	0 / 9
test	1000	27.98%	20.98%	3.46% / 75.72%	0 / 142

表 3　三种模型的测试性能汇总

模型	Dice 均值 ±SD	IoU	HD95 px	Sensitivity	Specificity	M
U-Net	0.5939 ±0.0218	0.4868	83.10	0.7115	0.8011	28.95
ResUNet	0.6077 ±0.0194	0.4955	85.16	0.6948	0.8244	30.35
Attention U-Net	0.6080 ±0.0148	0.4986	88.10	0.6917	0.8261	29.47

表 4　主实验逐种子结果与有效样本计数

tag	Dice	IoU	HD95	空预测	HD 有效	轮数	日志峰值轮
unet_s42	0.6062	0.4900	93.89	6	994	10	3
unet_s2026	0.5687	0.4643	74.66	21	979	9	2
unet_s7	0.6067	0.5061	80.74	28	972	10	3
resunet_s42	0.5857	0.4721	82.95	7	993	12	11
resunet_s2026	0.6150	0.5047	84.83	11	989	12	9
resunet_s7	0.6225	0.5098	87.69	7	993	12	7
attn_unet_s42	0.6226	0.5141	82.84	7	993	12	7
attn_unet_s2026	0.5930	0.4788	103.05	2	998	8	1
attn_unet_s7	0.6085	0.5029	78.41	15	985	12	11

表 5　单种子消融结果与训练耗时

设置	Dice	IoU	HD95 px	空 / HD 有效	轮数	总分钟
BCE	0.5313	0.4217	66.96	33 / 967	9	35.1
Dice	0.6026	0.4920	84.66	5 / 995	7	27.5
混合 / 256	0.6062	0.4900	93.89	6 / 994	10	44.8
192 输入	0.6391	0.5254	59.22	4 / 996	12	30.5
384 输入	0.5810	0.4753	124.24	15 / 985	8	64.3
g1/g2	0.5954	0.4769	95.07	1 / 999	8	35.0
g4	0.5938	0.4892	70.48	24 / 976	12	48.2
g1–g4	0.6226	0.5141	82.84	7 / 993	12	55.0

表 6　两模型五折验证结果

模型	折 0	折 1	折 2	折 3	折 4	均值±折间 SD
attn_unet	0.6000	0.6206	0.5723	0.5761	0.4467	0.5631 ±0.0679
resunet	0.6054	0.5615	0.5872	0.5140	0.5811	0.5698 ±0.0349

表 7　GT 框下三阶段最终测试结果

阶段	Dice	IoU	HD95 px	Sensitivity	Specificity	优化参数 M
E1	0.8691	0.7788	24.31	0.8469	0.8769	0
E2	0.9181	0.8529	14.55	0.9463	0.9443	4.06
E3	0.8970	0.8204	17.78	0.9330	0.9603	4.36

表 8　GT 框评测的有效计数与执行路径时延

阶段	空预测	HD 有效	Sens 有效	Spec 有效	原始 ms/图
E1	0	1000	1000	998	15.01
E2	0	1000	1000	998	15.08
E3	0	1000	1000	998	1909.35

表 9　E2 与 E3 训练过程统计

训练 tag	轮数	峰值轮	val 峰值	总分钟	平均秒/轮	中位秒/轮
e2_box	20	9	0.9205	17.15	51.5	51.8
e3_lora	6	2	0.9040	128.63	1286.3	1159.3

表 10　三阶段十类提示的最终 Dice

提示	E1 Dice	E2 Dice	E3 Dice
gt	0.8691	0.9181	0.8970
pert-10	0.7871	0.9127	0.8923
pert-20	0.5503	0.8779	0.8611
pert10	0.7855	0.9073	0.8839
pert20	0.6188	0.8825	0.8690
point1	0.7292	0.8399	0.8535
point3	0.7695	0.8569	0.8605
point5	0.7902	0.8638	0.8611
auto	0.3837	0.6918	0.7559
auto10	0.3556	0.6850	0.7451

表 11　自动框级联与上游模型的最终结果

模型	提示	Dice	IoU	HD95 px	空预测	HD 有效
unet_s42	无提示	0.6062	0.4900	93.89	6	994
E1	auto	0.3837	0.2983	93.41	0	1000
E1	auto10	0.3556	0.2722	95.84	0	1000
E2	auto	0.6918	0.5894	55.10	0	1000
E2	auto10	0.6850	0.5815	56.37	0	1000
E3	auto	0.7559	0.6549	49.86	0	1000
E3	auto10	0.7451	0.6421	52.34	0	1000

表 12　全部正式训练运行明细

tag	seed	size	loss	门控	实际轮	日志停止	峰值轮
attn_bottleneck	42	256	bce_dice	bottleneck	12	早停 6	5
attn_skip	42	256	bce_dice	skip	8	早停 6	1
attn_unet_s2026	2026	256	bce_dice	all	8	早停 6	1
attn_unet_s42	42	256	bce_dice	all	12	完成	7
attn_unet_s7	7	256	bce_dice	all	12	完成	11
cv_attn_unet_f0	42	256	bce_dice	all	12	早停 6	5
cv_attn_unet_f1	42	256	bce_dice	all	12	完成	12
cv_attn_unet_f2	42	256	bce_dice	all	11	早停 6	4
cv_attn_unet_f3	42	256	bce_dice	all	12	完成	7
cv_attn_unet_f4	42	256	bce_dice	all	9	早停 6	2
cv_resunet_f0	42	256	bce_dice	—	12	完成	10
cv_resunet_f1	42	256	bce_dice	—	8	早停 6	1
cv_resunet_f2	42	256	bce_dice	—	8	早停 6	1
cv_resunet_f3	42	256	bce_dice	—	8	早停 6	6
cv_resunet_f4	42	256	bce_dice	—	8	早停 6	1
loss_bce	42	256	bce	—	9	早停 6	2
loss_dice	42	256	dice	—	7	早停 6	1
resunet_s2026	2026	256	bce_dice	—	12	完成	9
resunet_s42	42	256	bce_dice	—	12	完成	11
resunet_s7	7	256	bce_dice	—	12	完成	7
size192	42	192	bce_dice	—	12	完成	6
size384	42	384	bce_dice	—	8	早停 6	2
unet_s2026	2026	256	bce_dice	—	9	早停 6	2
unet_s42	42	256	bce_dice	—	10	早停 6	3
unet_s7	7	256	bce_dice	—	10	早停 6	3

表 13　全部提示条件的 IoU 与失效计数

阶段	提示	IoU	HD95	空预测	HD 有效	Sens 有效	Spec 有效
e1	gt	0.7788	24.31	0	1000	1000	998
e1	pert-10	0.6625	27.75	0	1000	1000	998
e1	pert-20	0.3887	42.03	0	1000	1000	998
e1	pert10	0.6805	35.44	0	1000	1000	998
e1	pert20	0.5039	51.48	0	1000	1000	998
e1	point1	0.6241	40.82	0	1000	1000	998
e1	point3	0.6632	42.21	0	1000	1000	998
e1	point5	0.6862	39.36	0	1000	1000	998
e1	auto	0.2983	93.41	0	1000	1000	998
e1	auto10	0.2722	95.84	0	1000	1000	998
e2	gt	0.8529	14.55	0	1000	1000	998
e2	pert-10	0.8448	15.04	0	1000	1000	998
e2	pert-20	0.7965	18.97	0	1000	1000	998
e2	pert10	0.8360	16.79	0	1000	1000	998
e2	pert20	0.7988	20.88	0	1000	1000	998
e2	point1	0.7472	28.44	0	1000	1000	998
e2	point3	0.7648	31.05	0	1000	1000	998
e2	point5	0.7748	30.25	0	1000	1000	998
e2	auto	0.5894	55.10	0	1000	1000	998
e2	auto10	0.5815	56.37	0	1000	1000	998
e3	gt	0.8204	17.78	0	1000	1000	998
e3	pert-10	0.8151	17.71	0	1000	1000	998
e3	pert-20	0.7736	21.70	0	1000	1000	998
e3	pert10	0.8002	20.14	0	1000	1000	998
e3	pert20	0.7788	23.52	0	1000	1000	998
e3	point1	0.7674	24.87	0	1000	1000	998
e3	point3	0.7724	26.13	0	1000	1000	998
e3	point5	0.7732	25.95	0	1000	1000	998
e3	auto	0.6549	49.86	0	1000	1000	998
e3	auto10	0.6421	52.34	0	1000	1000	998

附录 B 修复验证与快速复现

B.1 修复验证

已完成 E2 20 轮、E3 6 轮与 384 输入问题实验的独立训练，随后完成 E2/E3 各 10 类提示与 384 输入的 1000 张测试评测。训练 best 轮次、日志峰值和 last 元数据一致；其余卷积权重核对通过，未扩大重跑范围。回归检查及逐像素编码复用核验通过。完整命令、日志、逐样本结果和哈希见验证记录/完整复验及 repository/RESULTS_RELEASE.json；历史文件单独归档。

B.2 获取代码并查看结果

仓库地址：https://github.com/12334rrr/graduate-machine-learning。本次修复与报告尚未推送远端，精确复用请进入压缩包 repository；远端基线为 4ac7b1ec。先运行以下命令检查文件、重算最终汇总并打开门户：

```
cd repository
python3 quick_reproduce.py check
python3 quick_reproduce.py summary
python3 quick_reproduce.py portal
```

浏览器访问 http://127.0.0.1:8800/#/hw1 或#/hw2。结果展示仅依赖 Python 标准库，不需要数据、训练权重或问答密钥。

B.3 训练与推理复验

完整环境、下载、训练及十类提示命令见 repository/QUICKSTART.md。保持 hw1_unet、hw2_sam、dataset_hub 同级，先准备 ISIC 数据和官方 SAM ViT-B 权重，再执行隔离小规模验证：

```
python quick_reproduce.py smoke unet
python quick_reproduce.py smoke e1
```

本次正式命令见 repository/QUICKSTART.md。需要重训时使用独立副本和新输出目录，完整训练采用连续运行避免分段续跑改变随机轨迹。提交包提供 E2/E3 及 384 输入的推理权重，原始数据、官方 SAM 基础权重和嵌入需按说明准备。

附录 C 实际前端与电子图录

前端把原始日志、源码和图片连接起来，用于复核实验。以下为本地实际页面截图；37 张原始画廊图以原字节保留在随包电子图录，避免重复占用报告页面。截图重新采集于正式结果更新后的页面；配色、提示矩阵和三级联比较与正文一致。



图 16　实际前端的卷积模型比较页面

注：真实页面截图；JSON 为指标来源。

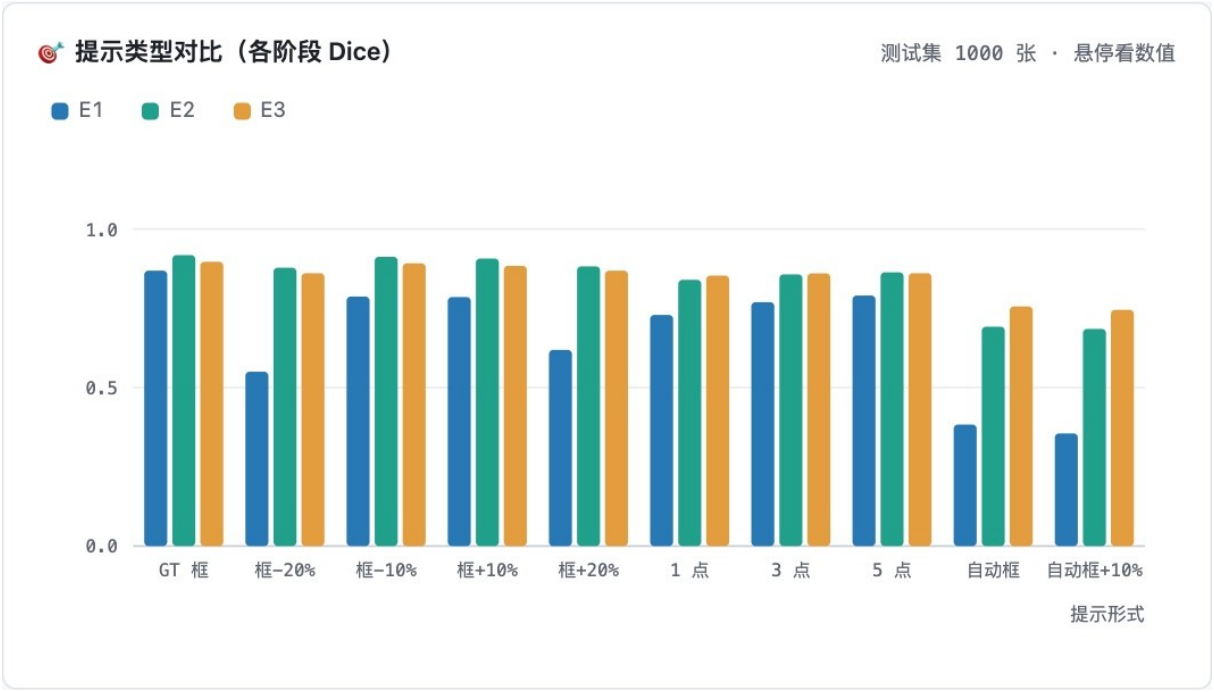


图 17　实际前端的 SAM 提示类型页面

注：页面与提示构造代码对应；原始图片目录见电子图录。