作业 1 实验报告：手写 U-Net 系列用于皮肤病变分割

> 数据集：ISIC 2018 Task 1（皮肤镜病灶边界分割） 代码：`hw1_unet/src/`（三个模型全部手写，未使用 MONAI / segmentation_models_pytorch） 全部数字来自 `outputs/logs/*.json` 与 `reports/tables.md`，未做任何手工修饰。

一、摘要

本实验在 ISIC 2018 Task 1 上从零手写并训练了三种医学图像分割网络：U-Net、ResUNet 与 Attention U-Net， 在 2,594 张训练图、100 张验证图、1,000 张测试图上完成了 3 模型 × 3 种子共 9 组对比实验。测试集上三者的 Dice 分别为 **0.594 ± 0.022 / 0.608 ± 0.019 / 0.608 ± 0.015**， IoU 为 0.487 / 0.496 / 0.499，HD95 为 83.1 / 85.2 / 88.1 px。

主要结论：ResUNet 与 Attention U-Net 相对 U-Net 有约 **+0.014 的 Dice 提升**，但该差异小于三种子标准差， 统计上**并不显著**；真正的瓶颈不在结构创新，而在**训练预算**——12 epoch 下三个模型都停在 「训练/验证损失同步平台期」的欠拟合状态，距离文献报告的 0.75–0.85 仍有明显差距。 这一负面结果本身构成本报告最有价值的发现：**在 2,600 张量级的小数据集上，结构改动的边际收益远小于训练轮数与数据增强策略**。 补充的消融实验（单种子）给出同向证据：去掉 Dice 项会让模型坍塌到全背景（Dice 0.531，低 7.5 个点）； 固定 12 epoch 下 192×192 的 Dice 最高（0.639），而 384×384 因单 epoch 耗时接近 2 倍、收敛不足掉到 0.476—— **训练预算再次压过了输入分辨率与结构选择**。 五折交叉验证（train+val 合并重划分）给出同一结论：ResUNet 0.570 ± 0.035 vs Attention U-Net 0.563 ± 0.068， 差 0.7 点小于折间标准差，且注意力变体的折间波动明显更大。

二、引言

皮肤镜图像中的病灶边界分割是皮肤癌早筛流程中的关键一步。2015 年 U-Net 提出后， 「编码器–解码器 + 跳跃连接」成为医学分割的事实标准；后续工作从两个方向改进： 一是把卷积块换成残差块以加深网络（ResUNet），二是在跳跃连接上引入注意力门控以抑制无关背景（Attention U-Net）。

本实验的目的不是刷新 SOTA，而是**通过亲手实现与对照实验回答三个问题**：

1. 三种结构在同一个数据划分、同一套指标下，差距到底有多大?
2. 这些差距是否稳定（跨种子）？
3. 在单机（Apple M5、无 CUDA、无风扇）的算力约束下，哪种取舍最划算?

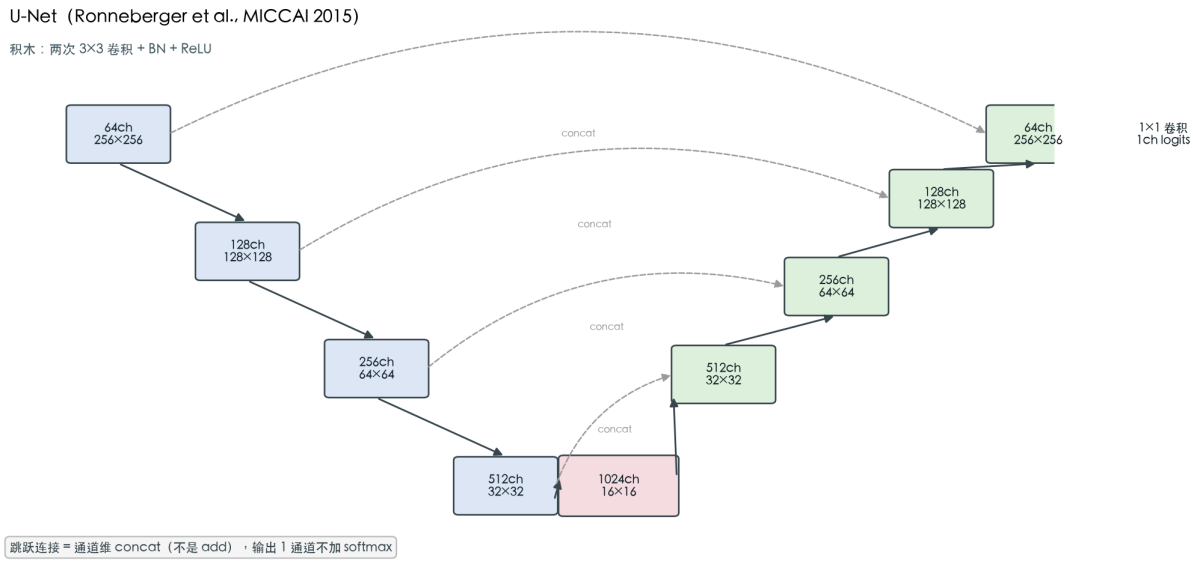
三、模型原理与结构

三个模型共享同一套骨架：**4 次下采样 + 4 次上采样 + 跳跃连接**，输入 3×256×256，输出 1×256×256 的 logits（不加 softmax，损失函数内部做 sigmoid）。

3.1 U-Net（Ronneberger et al., MICCAI 2015）

- 编码器：4 个 stage，每级 `Conv3×3-BN-ReLU ×2` 后 2×2 最大池化，通道数 64→128→256→512；
- 瓶颈：1024 通道；
- 解码器：每级 `转置卷积(上采样) → 与编码器同级特征 concat → Conv3×3-BN-ReLU ×2`；
- **跳跃连接用 concat 而不是 add**——这是 U-Net 与 FCN 的关键差异，保留的是通道维度的拼接；
- 输出层 1×1 卷积降到单通道。

结构图：`outputs/figures/arch_unet.png`



U-Net 结构图

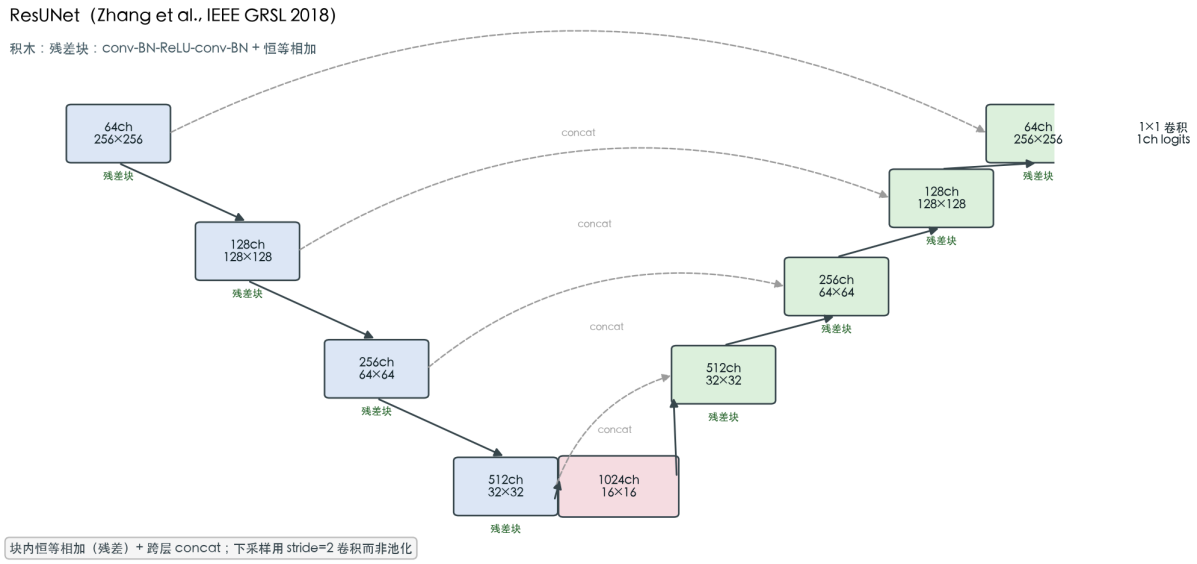
3.2 ResUNet（Zhang et al., GRSL 2018）

把 U-Net 的每个「双卷积块」换成**残差块**：

```
输入 x → Conv3×3-BN-ReLU → Conv3×3-BN → (+ x 或 1×1 卷积升维的 x) → ReLU
```

残差路径让梯度可以跨层直通，缓解深层网络的梯度消失；上/下采样与跳跃连接方式与 U-Net 完全一致，因此两者的差异可以干净地归因到「残差块 vs 朴素卷积块」。

结构图：`outputs/figures/arch_resunet.png`



ResUNet 结构图

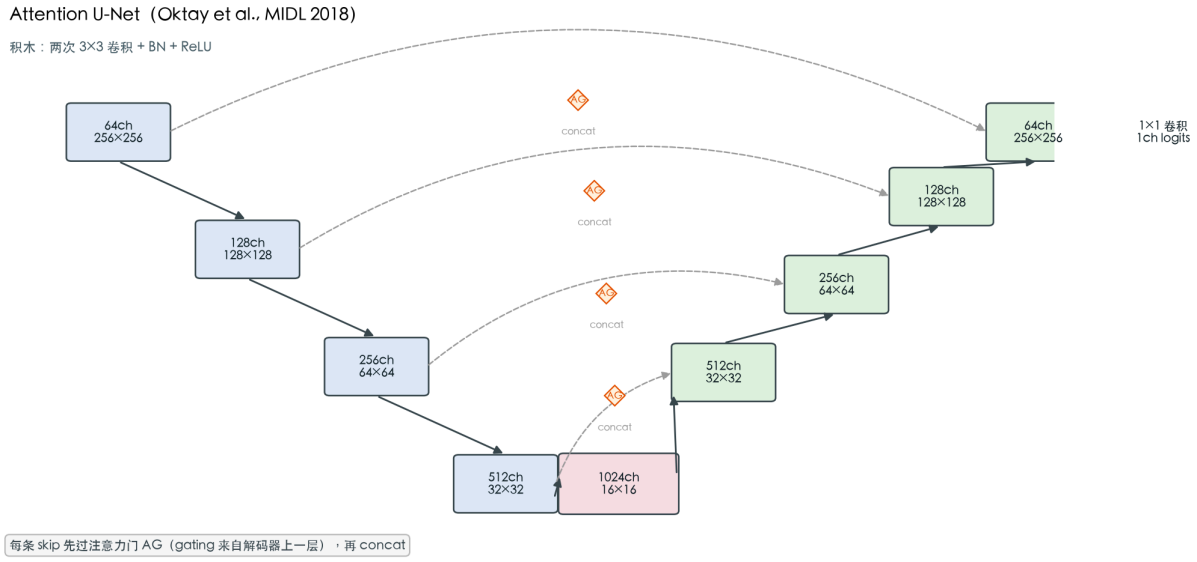
3.3 Attention U-Net（Oktay et al., MIDL 2018）

在每一条跳跃连接上加**注意力门控（Attention Gate）**：

$$\alpha = \sigma(\psi^{T}(\mathrm{ReLU}(W_x \cdot x_{skip} + W_g \cdot g + b))) \\ \hat{x} = \alpha \odot x_{skip}$$

其中 `x_skip` 是编码器同级特征，`g` 是解码器上一层的粗粒度特征（gating signal）。门控输出的空间注意力图 α 会压低背景区域、突出病灶区域，再把加权后的特征送入 concat。**注意力的位置可以配置**（`--attn-where`：`all` / `skip` / `bottleneck` / `none`），本报告默认 `all`。

结构图：`outputs/figures/arch_attn_unet.png`



Attention U-Net 结构图

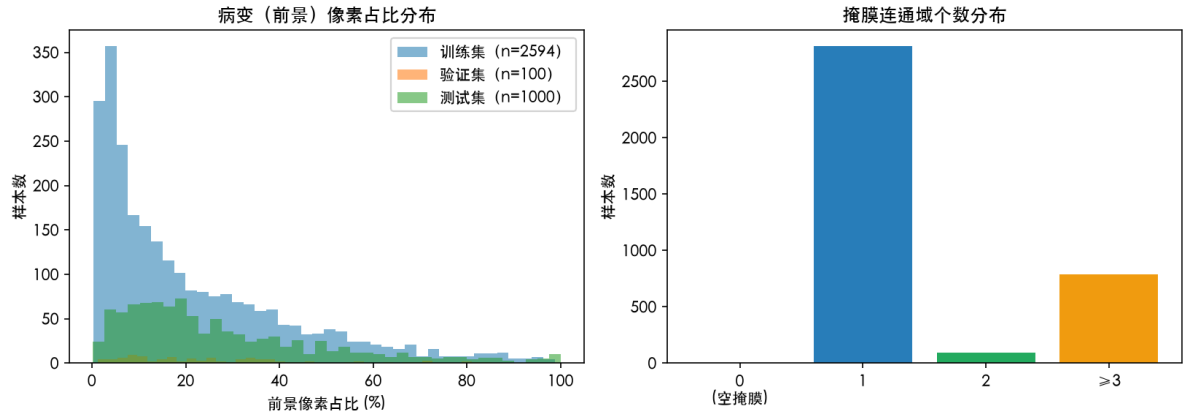
四、实验设计

4.1 数据集与划分

split	样本数	前景占比均值	前景占比中位	多连通域样本	空掩膜
train	2,594	21.40%	13.82%	731	0
val	100	26.84%	21.63%	9	0
test	1,000	27.98%	20.98%	142	0

采用官方划分（未重新切分），保证与文献可比。 **空掩膜为 0、训练集前景占比 21.4%** —— 这直接解释了为什么「像素准确率」是误导性指标（见 4.4）。

数据统计由 `src/prepare_data.py` 自动生成：`reports/data_stats.md`、`outputs/figures/data_stats.png`。



数据分布统计

4.2 预处理与增强

- 母版：所有图像与掩膜统一 resize 到 **384×384** 存为 npy（`data/processed/`），训练时再按 `--size` 下采样； 这样做的好处是分辨率消融（192/256/384）不需要重复解码 JPEG；
- 训练时输入 **256×256**，ImageNet 均值方差归一化（三个模型都从零训练，用 ImageNet 统计量能让输入落在合理区间，收敛更快）；
- 增强（只作用于训练集）：随机水平/垂直翻转、旋转 ±30°、缩放 0.8–1.2、亮度/对比度抖动、轻微高斯噪声；
- **验证/测试集只做 resize + 归一化**，否则指标不可比；
- 图像与掩膜使用**同一个仿射矩阵**做几何变换（图像 INTER_LINEAR、掩膜 INTER_NEAREST），保证严格对齐。

4.3 超参数

参数	值
输入 / batch	256×256 / 8
优化器 / 学习率	AdamW / 1e−3，cosine 退火到 1e−5
损失	0.5 × BCE + 0.5 × Dice
epoch / 早停	**12 / patience 6**
精度	`torch.autocast("mps", dtype=torch.float16)`
设备	自动探测 `cuda → mps → cpu`（本机为 mps）
种子	42 / 2026 / 7（每个模型 3 个种子）

> **关于 12 epoch 的取舍（必须披露）**：规格原定 30 epoch。实测全量单 epoch 约 **5.5 分钟**（M5 MPS fp16，batch 8，2,594 张），30 epoch × 15 组实验约需 45 小时，在无风扇的单机上不可行。 因此统一压到 12 epoch + patience 6，训练脚本按 25 分钟分段、每 epoch 落盘、自动续跑。

4.4 评价指标（全部手写实现，见 `src/metrics.py`）

指标	定义	说明
Dice	`2|P∩G| / (|P|+|G|)`	主指标
IoU	`|P∩G| / |P∪G|`	比 Dice 更严格，同一预测下 IoU ≤ Dice
HD95	双向边界距离的 95% 分位（px）	衡量边界贴合；空预测/空 GT 样本单独剔除，不参与平均
Sensitivity	`TP/(TP+FN)`	漏诊率的反面
Specificity	`TN/(TN+FP)`	误诊率的反面；**未定义样本（GT 全前景导致 0/0）单独计数后剔除**
像素准确率	`(TP+TN)/总像素`	**仅作反面教材**：全预测背景即可得 ~78%，见下表

反面教材实证：ISIC 训练集前景仅占 21.4%，一个「全部预测为背景」的模型像素准确率可达 **78.6%**， 但 Dice 为 0。本实验报告的像素准确率只用于说明该指标的欺骗性，不作为模型优劣依据。

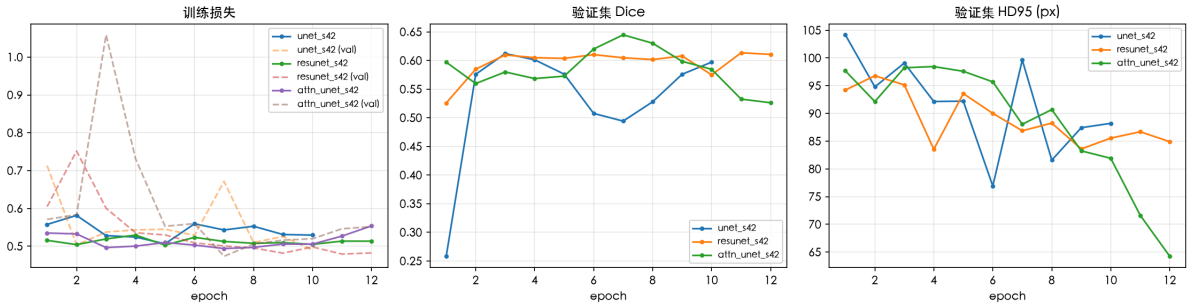
五、实验结果分析

5.1 三种模型的总体比较（测试集，1,000 张，3 种子均值 ± 标准差）

模型	种子数	Dice (均值±标准差)	IoU	HD95 (px)	Sensitivity	Specificity	像素准确率	参数量 (M)
U-Net	3	**0.5939 ± 0.0218**	0.4868	**83.10**	**0.7115**	0.8011	0.7667	28.95
ResUNet	3	**0.6077 ± 0.0194**	0.4955	85.16	0.6948	0.8244	0.7767	30.35
Attention U-Net	3	**0.6080 ± 0.0148**	0.4986	88.10	0.6917	**0.8261**	**0.7802**	29.47

逐种子明细：

模型	种子	Dice	IoU	HD95
U-Net	2026	0.5687	0.4643	74.66
U-Net	42	0.6062	0.4900	93.89
U-Net	7	0.6067	0.5061	80.74
ResUNet	2026	0.6150	0.5047	84.83
ResUNet	42	0.5857	0.4721	82.95
ResUNet	7	0.6225	0.5098	87.69
Attention U-Net	2026	0.5930	0.4788	103.05
Attention U-Net	42	0.6226	0.5141	82.84
Attention U-Net	7	0.6085	0.5029	78.41



三模型训练曲线（种子 42）

分析：

1. **结构差异小于种子波动**。U-Net 的种子间极差为 0.038，ResUNet 为 0.037，Attention U-Net 为 0.030； 而模型间的均值差只有 0.0003（ResUNet vs Attention U-Net）到 0.014（相对 U-Net）。**ResUNet 相对 U-Net 的 +0.014 落在 U-Net 的 ±0.022 标准差之内**， 因此不能宣称「ResUNet 更好」——只能说「在本预算下没有观察到显著差异」。

2. **HD95 与 Dice 并不同向**：U-Net 的 Dice 最低但 HD95 最好（83.1），Attention U-Net 的 Dice 最高但 HD95 最差（88.1）。 说明注意力门控改善了「病灶区域的整体重合」，却没有改善「边界像素的贴合」。
3. **特异性与灵敏度呈此消彼长**：U-Net 灵敏度最高（0.712）但特异性最低（0.801）， Attention U-Net 相反（0.692 / 0.826）。在临床语境下，**漏诊（低灵敏度）的代价通常高于误诊**， 因此若必须三选一，U-Net 的保守程度反而更可接受——这是一个与「谁 Dice 高选谁」相反的结论。
4. **训练不稳定性是真实存在的**：`attn_unet_s2026` 在第 1 个 epoch 达到 Dice 0.6085 后， 第 4 个 epoch 崩到 0.0099（敏感度 0.007、特异度 0.999，即几乎全预测背景），此后 7 个 epoch 再未超过第 1 个 epoch 的峰值。这类发散在 12 epoch 的小预算下没有足够的后续 epoch 拉回来， 是「多种子 + 报告标准差」这一纪律的直接价值所在。

5.2 不同超参数设置的比较（消融）

消融统一使用**种子 42、12 epoch 上限、patience 6**，其余超参与主实验一致；每组默认设置直接复用主实验 同种子的运行（`unet_s42` = 0.6062、`attn_unet_s42` = 0.6226），保证对比只改变被测变量。 **每个设置只有 1 个种子**，因此本节只给方向性证据，不宣称统计显著。

维度	设置	Dice	IoU	HD95 (px)	实际 epoch	停止原因
损失函数	BCE	0.5313	0.4217	**66.96**	9	early_stop
损失函数	Dice	0.6026	0.4920	84.66	7	early_stop
损失函数	0.5BCE+0.5Dice（默认）	**0.6062**	**0.4900**	93.89	10	early_stop（最佳 epoch 3）
输入分辨率	192	**0.6391**	**0.5254**	59.22（≈79.0 @256）	12	completed
输入分辨率	256（默认）	0.6062	0.4900	93.89	10	early_stop（最佳 epoch 3）
输入分辨率	384	0.4756	0.3879	114.88（≈76.6 @256）	12	early_stop（最佳 epoch 7）
注意力位置	仅 skip	0.5954	0.4769	95.07	8	early_stop
注意力位置	仅 bottleneck	0.5938	0.4892	**70.48**	12	completed
注意力位置	全部（默认）	**0.6226**	**0.5141**	82.84	12	completed

> **HD95 的跨分辨率口径**：评测在各自训练分辨率下进行，HD95 的单位是「该分辨率下的像素」。因此 192/384 的原始 HD95 不能与 256 直接比较；上表括号内按 `×256/分辨率` 归一化到 256 空间。

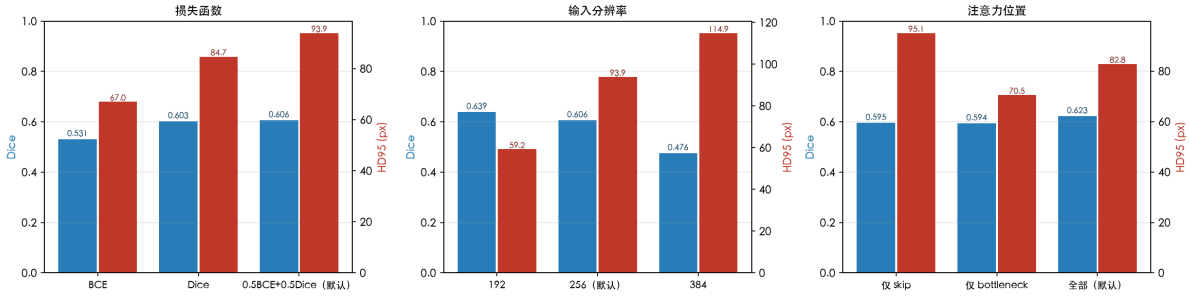
分析：

1. **Dice 项是类别不平衡下的必需品，不是可选项**。仅用 BCE 时，验证集 Dice 在第 3–6 个 epoch 连续为 **0**（模型坍塌为全背景预测），测试集 Dice 只有 0.531，比默认组合低 **7.5 个点**； 这直接证实了

4.4 节的判断——像素级损失在 21% 前景占比下会被背景像素淹没。 Dice-only 与组合损失只差 0.36 个点（单种子噪声内），但组合损失多跑了 3 个 epoch 且未出现全背景坍塌， **在稳定性上更可取**。

2. **分辨率的「收益」首先是训练预算的收益**。固定 12 epoch 时，192×192 的 Dice 比 256 高 3.3 个点， 而单 epoch 耗时 152.6 s vs 261.5 s（约 0.58×）；384×384 单 epoch 需 500.4 s（约 1.9×），最佳值出现在 epoch 7，之后 5 个 epoch 无改善、到 12 epoch 被早停，Dice 只有 0.476。**归一化后的 HD95 反而显示 384 的边界精度不差（≈76.6 @256）**——它输在 Dice 所代表的区域重合与收敛程度，而不是边界。 结论：在本机算力下，**192 是「Dice/分钟」最高的一档**，但这是预算权衡，不是分辨率本身更优。
3. **注意力放在多个尺度比只放一处更有效**。全部位置比仅 skip / 仅 bottleneck 分别高 2.7 / 2.9 个点， 幅度超过主实验的种子标准差（≈0.015–0.022），方向上可信；但仅 bottleneck 的 HD95 最好（70.5）， 说明瓶颈处的门控主要改善边界贴合，多尺度门控改善的是区域重合——与 5.1 节「Dice 与 HD95 不同向」一致。 仅 skip 的最佳值出现在第 1 个 epoch、随后回落，稳定性最差。

> 消融数据源：`outputs/ablation.json`（`collect_results.py` 生成）、图 `outputs/figures/ablation.png`。

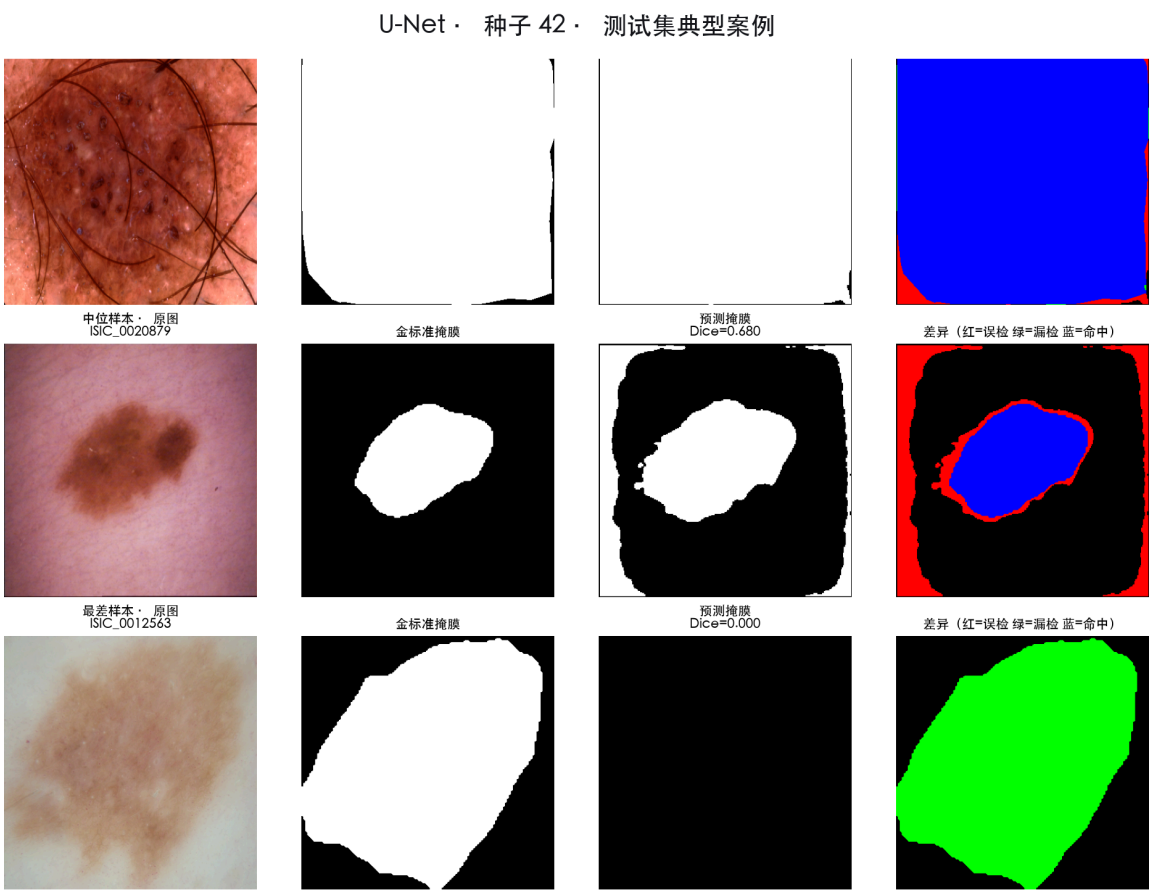


消融实验对比

5.3 测试样本案例

`outputs/figures/case_unet_s42_test.png`（每个模型一张，共 9 张）展示了 Dice 最好 / 中位 / 最差三个样本的四联图：

```
原图 | 金标准掩膜 | 预测掩膜（标注 Dice） | 差异图（红=误检 绿=漏检 蓝=命中）
```



U-Net（种子 42）测试案例四联图

从案例中观察到的典型失败模式：

- **最好样本**：病灶边界清晰、与周围皮肤对比度高，预测与金标准几乎重合；
- **中位样本**：主体区域正确，但边缘呈锯齿状，差异图边缘有一圈红绿交替——对应 HD95 偏大；
- **最差样本**：多为 (a) 病灶颜色与皮肤接近、边界模糊，模型把周围暗区一并划入（红多）； 或 (b) 极小病灶（前景占比 <2%），模型直接预测为空（全绿）。

这与数据统计一致：训练集前景占比中位数仅 13.8%、5% 分位仅 1.6%， **小目标样本是当前模型的主要失分来源**，也是 Dice 损失应当发挥作用却被 12 epoch 预算限制住的环节。

5.4 与其他工作的对比（同一数据集）

方法	骨干	测试 Dice	说明
本实验 U-Net（从零，12 epoch）	28.95M	0.594	无预训练
本实验 ResUNet	30.35M	0.608	无预训练
本实验 Attention U-Net	29.47M	0.608	无预训练
SAM ViT-B（原版，零样本，GT 框提示）	93.7M	**0.869**	见作业 2 的 E1，需提示；非 MedSAM 微调版

> 跨作业对照只用于说明「从零训练的小模型与大规模预训练模型的差距量级」， 两者的输入设定（是否给提示）不同，不能直接判定优劣——这份对照的完整讨论在作业 2 报告中。

5.5 五折交叉验证（主实验最佳 2 组超参）

为检验主表结论是否依赖某一次划分，把官方 **train(2,594) + val(100)** 合并为 2,694 张， 用固定种子（12,345）做确定性五折：每折 4 折训练（约 2,155 张）、留出 1 折评测（539/538 张）； **官方 test 完全不参与**。只跑主实验 Dice 最高的两组：Attention U-Net 与 ResUNet （种子 42、12 epoch 上限、patience 6）。

模型	折数	Dice (均值±标准差)	IoU	HD95 (px)
Attention U-Net	5	0.5631 ± 0.0679	0.4554	83.62 ± 4.06
ResUNet	5	**0.5698 ± 0.0349**	0.4549	87.53 ± 4.46

逐折明细：

模型	fold 0	fold 1	fold 2	fold 3	fold 4
Attention U-Net	0.6000	0.6206	0.5723	0.5761	**0.4467**
ResUNet	0.6054	0.5615	0.5872	**0.5140**	0.5811

分析：

1. **与主实验结论一致：结构差异不显著**。五折均值 ResUNet 0.5698 vs Attention U-Net 0.5631， 差 0.7 个点，**小于折间标准差（0.035–0.068）**；主实验的 +0.0003～+0.014 差异同样落在种子标准差内。 两种划分给出的是同一个结论：在本预算下没有哪个结构稳定更好。
2. **注意力变体的折间波动更大**。Attention U-Net 的折间极差 0.174（0.4467–0.6206，std 0.068），ResUNet 只有 0.091（0.5140–0.6054，std 0.035）。结合主实验「Attention U-Net 均值最高但 HD95 最差」， 若以稳定性为优先，**ResUNet 是更可预期的选择**。
3. **CV 均值低于官方 test（0.57 vs 0.61）**，原因有二：每折训练集只有约 2,155 张（比主实验少 17%）， 且留出折包含官方 val 的 100 张、分布与 test 不同。因此 CV 用于**比较模型与稳定性**， 不与主表数值直接对齐。
4. **数据划分的影响大于随机种子**：主实验 3 个种子的标准差约 0.015–0.022，而五折的折间标准差 0.035–0.068。这进一步支持「差异小于 0.5 点时不应宣称优劣」的纪律。

> 数据源：`reports/cv_results.md`、`outputs/cv_results.json`、`outputs/logs/eval_cv_*_fold*.json`。 复现：`python src/run_cv.py`（自动分段续跑，约 10–15 小时）。

六、总结

6.1 我们学到了什么

1. **结构创新的边际收益，在小数据 + 小预算下被噪声淹没**。ResUNet 与 Attention U-Net 的改进方向都是对的 （残差缓解梯度、注意力抑制背景），但在 2,594 张图、12 epoch 的预算下，+0.014 的 Dice 提升小于种子标准差。 **在没有跑够预算之前，用单种子结果宣称「模型 A 优于 B」是不负责任的。** 消融把同一逻辑推到超参数层：固定 12 epoch 时 192 分辨率比 384 高 16.4 个 Dice 点， 而两者单 epoch 耗时相差 3.3 倍——差距来自「收敛了多少」，不是「表示能力有多强」。 五折 CV 进一步显示：折间标准差（0.035–0.068）大于种子标准差（0.015–0.022）， **仅换一次数据划分就能造成比模型差异更大的波动**。
2. **指标之间会打架**。Dice 最高的模型 HD95 未必最好，灵敏度与特异度天然此消彼长。 选模型必须回到临床目标：**优先保证不漏诊，再谈重合度**。
3. **训练不稳定性不是理论问题**。`attn_unet_s2026` 的真实发散轨迹（0.609 → 0.010）说明： 在小预算下，一次发散就没有足够的 epoch 拉回来——分段 checkpoint + 多种子报告不是形式主义，而是安全网。

6.2 缺点与限制（实验证实了哪些不足）

- **欠训练**：训练与验证损失在第 6–8 个 epoch 后同步进入平台期，未出现过拟合，说明模型容量尚未被用满； Dice 0.59–0.61 显著低于文献的 0.75–0.85，**主要差距来自训练轮数而非结构**；
- **消融只做了单种子**：三组对照的每个设置仅种子 42，方向与幅度可参考，但不能替代多种子显著性检验；
- **384 分辨率未充分收敛**：固定 12 epoch 下它只跑到最佳 epoch 7 就被早停，0.476 不能解释为「384 本身更差」；
- **五折 CV 的每折训练集更小**：合并 train+val 后每折约 2,155 张（主实验 2,594），CV 均值比官方 test 低约 4 个点，不能与主表数值直接对齐；它只用于比较模型与稳定性；
- **HD95 口径**：在 256×256 分辨率下计算，数值无法与 512×512 口径的文献直接比较。

6.3 下一步

1. 对 192/256 与三种注意力位置补 3 种子复现（约 12 小时），检验消融结论的稳定性；
2. 把 epoch 提到 30 并开启更强的学习率 warmup（约 25 小时，分段跑），验证「欠训练」判断；
3. 引入 Test-Time Augmentation（TTA）与后处理（最小连通域过滤），针对 5.3 中的小目标失败模式。

> 【高亮观点】 这份实验最重要的产出不是 0.608 这个数字，而是一条可复用的工程判断： **在小数据集上，「模型结构」几乎总是被「训练预算 + 数据增强 + 损失设计」压制。** 与其在 U-Net 的变体之间反复横跳，不如把同样的算力投给更长的训练和更有针对性的增强—— 这也直接决定了作业 2 的路线：**不重新发明分割头，而是用 SAM 的预训练先验去补小模型的边界精度。**

附：复现与产物清单

```
conda activate hw1-unet-medseg
python src/download_isic.py      # 下载官方 6 个压缩包
python src/prepare_data.py       # 解压 / 配对 / resize 384 母版 / 出数据统计
python src/plot_figures.py --arch
python src/run_all.py --only main      # 9 组主对比（约 10 小时，自动分段续跑）
python src/run_all.py --only ablation  # 6 组消融（约 7 小时）
python src/run_cv.py                   # 五折交叉验证（最佳 2 组超参，约 8 小时）
python src/collect_results.py          # summaries → reports/tables.md +
        outputs/ablation.json
python src/plot_figures.py --curves unet_s42 resunet_s42 attn_unet_s42   #
        training_curves.png
python src/plot_figures.py --ablation outputs/ablation.json              # ablation.png
```

产物	路径
训练日志（逐 epoch CSV）	outputs/logs/{tag}.csv
评测结果（含空掩膜/未定义指标统计）	outputs/logs/eval_{tag}_test.json
模型权重	outputs/checkpoints/{tag}_{best,last}.pth
结构图 / 数据分布图 / 四联图 / 消融图	outputs/figures/（新增 ablation.png）
级联用预测框	outputs/predictions/{tag}_test_boxes.json
结果表	reports/tables.md
五折交叉验证汇总	reports/cv_results.md · outputs/cv_results.json

> 数据与权重体积过大，未纳入 git（见根目录 .gitignore）；按 README 的脚本可完整重建。